〈 Improving Language Understanding by Generative Pre-Training (GPT-1) 〉

- 어떤 문제를 해결하려 했는가? (Abstract)

1. 지도학습 한계

2. 라벨링 데이터 부족의 문제

→ 대량의 비라벨 텍스트로 Language Model 을 사전학습(pre-training)한 후 각 태스크에 대해 미세 조정 학습(fine-tuning)을 하면 성능을 크게 향상시킬 수 있음

- 연구 동기와 문제점 (Introduction)

1. 지도 학습 의존성

: 라벨 없는 텍스트 데이터에서 언어 지식을 학습하는 방법의 필요

2. 표현 전이(Transfer Learning)의 어려움

: 기존 연구에서는 단어 임베딩(Word2Vec), 문장 임베딩의 방식 사용 → 단어 정보만 전달된다는 문제

- 연구의 목표

: 하나의 모델이 다양한 NLP task 로 전이 가능한 공통 형태(universal representation)을 학습하도록 하는 것 → Unsupervised Pre-training + Supervised Fine-tuning 의 2-stage 학습 제안

- 연구 접근법 및 모델 구조 (Method)

Stage 1 - Unsupervised Language Model Pre-training

: 대량의 텍스트에서 Language Modeling Objective 학습 → 이전 단어 기반 다음 단어 확률 예측

$$L_1(\mathcal{U}) = \sum_i \log P(u_i | u_{i-k}, \ldots, u_{i-1}; \Theta)$$

Stage 2 - Supervised Fine-tuning

: 사전학습된 모델 위에 선형 분류기 추가

$$L_2(\mathcal{C}) = \sum_{(x,y)} \log P(y | x^1, \ldots, x^m).$$

Textual Entailment (자연어 추론)

문제 구조

- 추론(premise) **p**
- 가설(hypothesis) **h**

중간에 구분자 토큰 $ 추가

$$[p \$ h]$$

두 문장을 이어붙여 하나의 시퀀스로 만든다.

Similarity (문장 유사도)

문제 구조

- 두 문장 A, B의 유사도를 판단.
- 하지만 A, B는 순서가 없음.

두 가지 순서를 모두 처리

1. $[s_1 \$ s_2]$
2. $[s_2 \$ s_1]$

각각 모델에 통과시켜 벡터를 얻고 더한 뒤 선형층(linear layer)에 입력한다.

Question Answering (질의 응답) &Commonsense Reasoning(상식 추론)

문제 구조

- 문서 z, 질문 q, 후보 답들 {ak}

각 후보마다 하나의 시퀀스 생성

$$[z \$ q \$ a_k]$$

후보가 4개면 → 모델을 4번 실행.

각 시퀀스에서 점수 계산
→ 후보들 사이에서 softmax
→ 가장 확률 높은 답 선택.

- 실험 구성 및 결과 (Experiments)

1. 사전 학습 데이터 셋 : BooksCorpus 책 데이터 사용
2. 실험 Task 총 4 가지

2-1. Natural Language Inference

2-2. Question Answering

2-3. Semantic Similarity

2-4. Text Classification

- 무엇을 발견했고 한계점은 무엇인지 (Discussion)

1. Layer Transfer 효과 : 더 많은 레이어를 전이할 수록 성능 증가
2. LM 자체 task 능력 일부 학습
3. Transformer + pre-train 방법이 성능 좋음

- 결론 및 주요 요약 (Conclusion)

: Generative Pre-training + Fine-tuning 으로 하나의 모델, 다양한 NLP 수행 가능

→ NLP 에서 Universal Language Model 가능성 제시, 이후 GPT-2, 3 의 기반

〈 DeepSeek – R1 〉

– 어떤 문제를 해결하려 했는가? (Abstract)

: LLM 의 주요 능력 중 하나, 추론 능력

1. 인간이 만든 추론 데이터 필요

2. Supervised Fine-Tuning 비용 높음

3. 추론 전략이 인간 데이터에 제한됨

→ Reinforcement Learning 기반 reasoning 학습 제안

– 연구 동기 및 문제점 (Introduction)

1. CoT Prompting 의 문제 : 추론 패턴, 사람 직접 작성

2. SFT 기반 추론 : 추론 패턴의 제한, 데이터 제작 비용 높음

3. RLHF 기반 접근

→ 모델이 스스로 추론 전략을 발견하도록 설계하자

– 연구 접근법 및 모델 구조 (Method)

DeepSeek – R1

1. Cold Start SFT

2. First RL Stage

3. Rejection Sampling & SFT

4. Second RL Stage

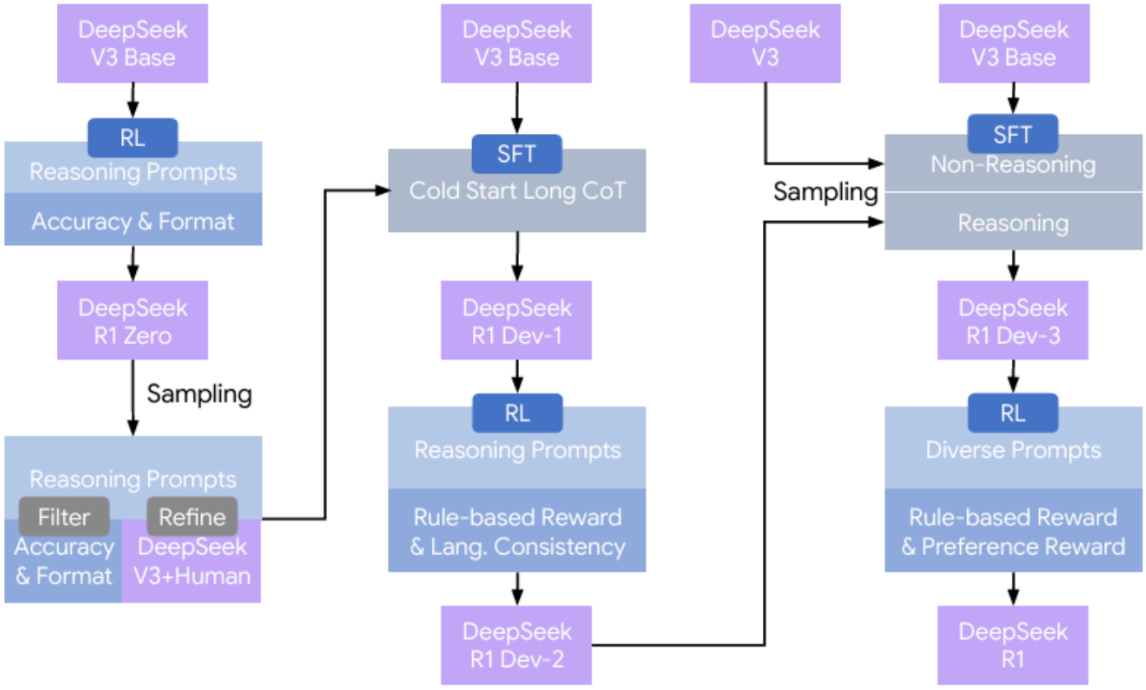

- 실험 구성 및 결과(Experiments)

	Benchmark (Metric)	R1-Zero	R1-Dev1	R1-Dev2	R1-Dev3	R1
English	MMLU (EM)	88.8	89.1	**91.2**	91.0	90.8
	MMLU-Redux (EM)	85.6	90.0	93.0	93.1	92.9
	MMLU-Pro (EM)	68.9	74.1	83.8	83.1	**84.0**
	DROP (3-shot F1)	89.1	89.8	91.1	88.7	**92.2**
	IF-Eval (Prompt Strict)	46.6	71.7	72.0	78.1	**83.3**
	GPQA Diamond (Pass@1)	**75.8**	66.1	70.7	71.2	71.5
	SimpleQA (Correct)	30.3	17.8	28.2	24.9	30.1
	FRAMES (Acc.)	82.3	78.5	81.8	81.9	**82.5**
	AlpacaEval2.0 (LC-winrate)	24.7	50.1	55.8	62.1	**87.6**
	ArenaHard (GPT-4-1106)	53.6	77.0	73.2	75.6	**92.3**
Code	LiveCodeBench (Pass@1-COT)	50.0	57.5	63.5	64.6	**65.9**
	Codeforces (Percentile)	80.4	84.5	90.5	92.1	**96.3**
	Codeforces (Rating)	1444	1534	1687	1746	**2029**
	SWE Verified (Resolved)	43.2	39.6	44.6	45.6	**49.2**
	Aider-Polyglot (Acc.)	12.2	6.7	25.6	44.8	**53.3**
Math	AIME 2024 (Pass@1)	77.9	59.0	74.0	78.1	**79.8**
	MATH-500 (Pass@1)	95.9	94.2	95.9	95.4	**97.3**
	CNMO 2024 (Pass@1)	**88.1**	58.0	73.9	77.3	78.8
Chinese	CLUEWSC (EM)	93.1	92.8	92.6	91.6	92.8
	C-Eval (EM)	**92.8**	85.7	91.9	86.4	91.8
	C-SimpleQA (Correct)	66.4	58.8	64.2	66.9	63.7

R1 Dev1
- Instruction-following 능력 향상
  - IF-Eval, ArenaHard
- 하지만 cold-start 데이터 규모가 작아 추론 성능 일부 감소
  - AIME

R1 Dev2
- Reasoning 중심 RL 학습으로 추론 성능 향상
  - Code generation, Math, STEM
- 그러나 사용자 선호 기반 벤치마크에서는 개선이 제한적
  - AlpacaEval2.0

R1 Dev3
- Reasoning + Non-reasoning 데이터 SFT
- 추론 능력 + 일반 언어 생성 능력 동시 향상
  - AlpacaEval2.0, Aider-Polyglot

R1 Dev4
- 코드·수학 성능은 소폭 향상
- 대신 Instruction-following 및 사용자 선호 성능 크게 개선
  - AlpacaEval2.0, ArenaHard

- 무엇을 발견했고 한계점은 무엇인가? (Discussion)

1. RL 만으로 추론 가능

2. 추론 길이 증가