〈 Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks 〉

- 어떤 문제를 해결하려 했는가? (Abstract)

1. 파라미터에 저장된 지식, 업데이트 불가능 문제
2. 출저 제공의 어려움
3. 할루시네이션(hallucination) 문제 발생 가능

- 연구 동기와 문제점 (Introduction)

1. Parametric Model : 지식을 모델 파라미터에 저장, 검색 없이 답 생성
2. Retrieval-based Model : 문서를 검색하여 답 추출

→ 2 가지 구조를 결합한 하이브리드 모델 설계

→ Parametric memory(LLM) + Non-parametric memoy(retrieval DB)를 결합한 모델 RAG 제안

- 연구의 목표 : 검색기 + 생성기를 결합한 모델, RAG 구조 제안

- 연구 접근법 및 모델 구조 (Method)

1. Retriever (검색기) : DPR 사용, 질문과 관련된 Top-K 검색
2. Generator (생성기) : BART 사용, 최종 답변 생성

→ Retriever + Generator end-to-end 학습 가능

- 실험 구성 및 결과 (Experiments)

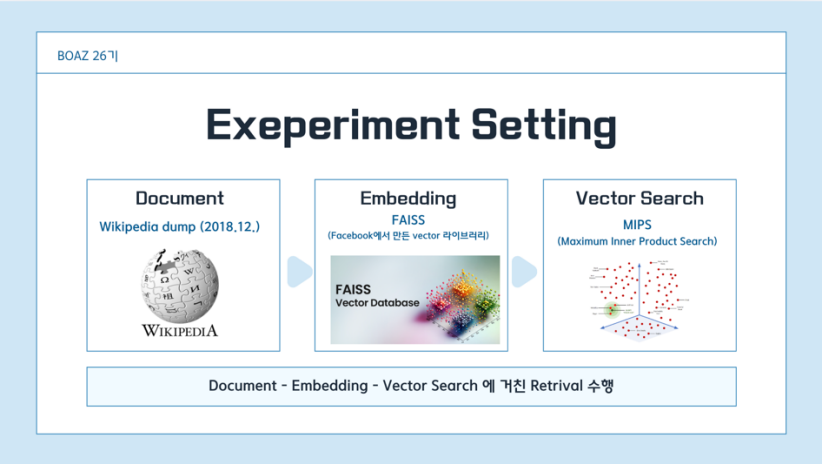

	Model	NQ	TQA	WQ	CT
Closed Book	T5-11B [52]	34.5	- /50.1	37.4	-
	T5-11B+SSM[52]	36.6	- /60.5	44.7	-
Open Book	REALM [20]	40.4	- / -	40.7	46.8
	DPR [26]	41.5	**57.9**/ -	41.1	50.6
	RAG-Token	44.1	55.2/66.1	**45.5**	50.0
	RAG-Seq.	**44.5**	56.8/**68.0**	45.2	**52.2**

- RAG 구조의 단순성에서도 SOTA 성능 가능

- 무엇을 발견했고 한계점은 무엇인지 (Discussion)

장점 : 할루시네이션 감소, 지식 확장 가능, Retrieval + Generation 시너지

단점 : Retrieval 품질 의존, 대규모 인덱스 필요, 계산 비용 증가

- 결론 및 주요 요약 (Conclusion)

: 언어모델에 외부 지식 검색 기능을 결합한 최초의 일반적인 프레임워크(RAG)를 제안

〈 LORA : LOW-RANK ADAPTATION OF LARGE LANGUAGE MODELS 〉

- 어떤 문제를 해결하려 했는가? (Abstract)

: document 를 제대로 활용하지 못함 → 여러 문서를 더 잘 활용해서 정답 생성 성능을 높이자

- 연구 동기 및 문제점 (Introduction)

1. Retrieval-based QA 문제 : 여러 문서 정보 통합의 어려움
2. RAG 구조의 한계 : 입력 길이 제한, document 별 정보 구분 어려움, 중요 정보 희석

→ 모델이 충분히 이해하고 활용하지 못함

- 연구 접근법 및 모델 구조 (Method)

: 문서 별 인코딩 후 디코더에서 결합

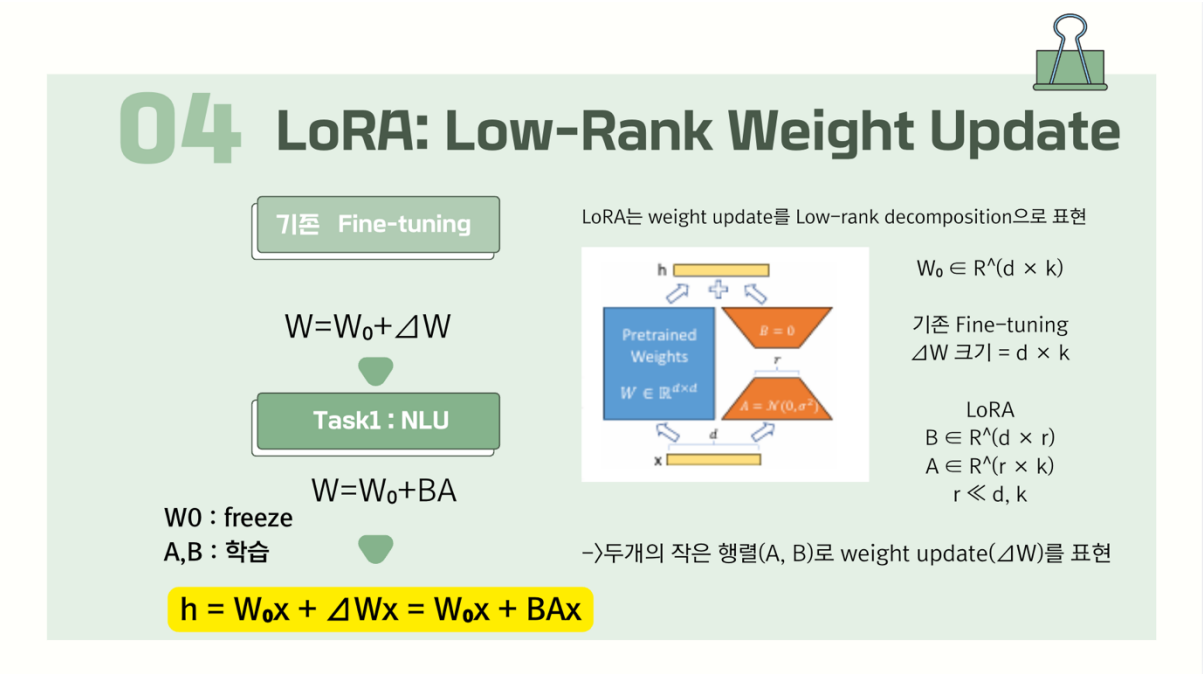

- 실험 구성 및 결과(Experiments)

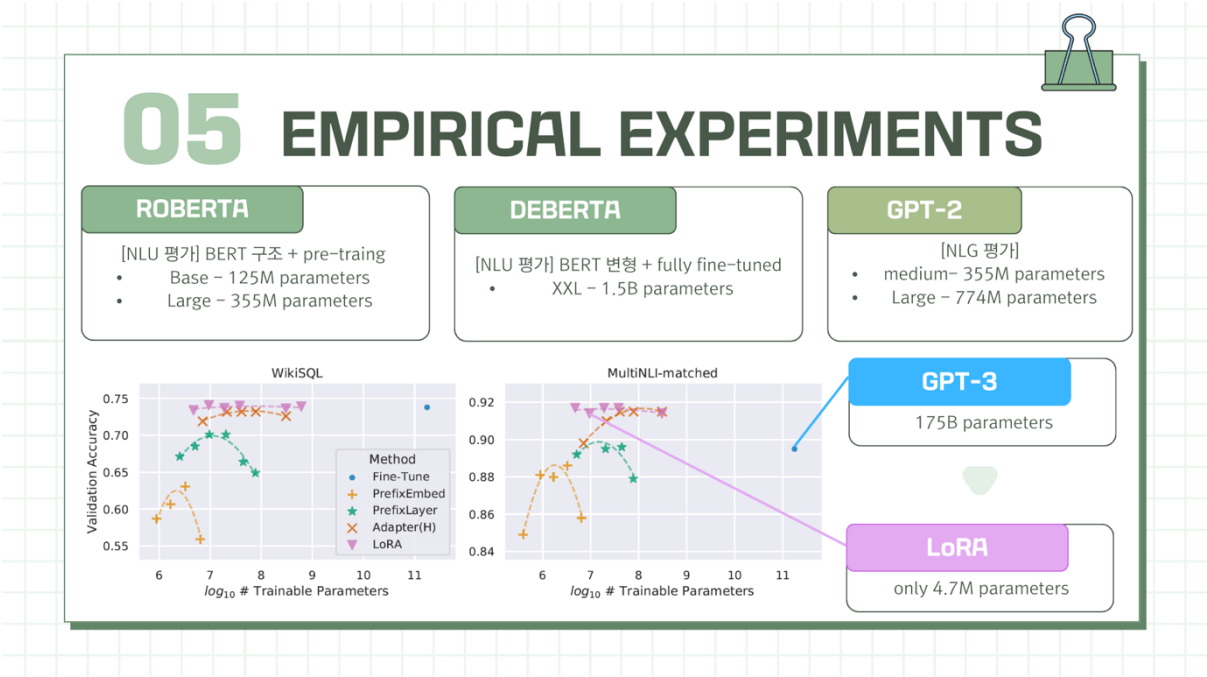

FiD 가 거의 모든 task 에서 최고 성능

1. Top-K 증가 효과

2. documeny 활용 능력 향상 : 여러 문서에서 정보 통합 능력 증가

- 무엇을 발견했고 한계점은 무엇인가? (Discussion)

1. 문서를 잘 쓰는게 중요

2. decoder 핵심 역할

3. multi-document reasoning 가능