〈 Generative Adversarial Nets 〉

- 어떤 문제를 해결하려 했는가? (Abstract)

1. 기존의 딥러닝은 데이터를 분류하는 모델(Discriminative)에 비해, 새로운 데이터를 만드는 모델(Generative)은 성능이 떨어짐
2. 복잡한 확률 계산을 피하면서도 실제와 같은 데이터를 생성하는 새로운 프레임워크 제안
3. 두 모델(생성자 G, 판별자 D)이 서로 경쟁하며 학습하는 '적대적 과정'을 도입

- 연구 동기와 문제점 (Introduction)

1. 이전의 생성 모델들은 수학적으로 계산이 불가능한 부분이 많아 다루기 매우 어려움
2. 기존에는 볼츠만 머신(RBMs)처럼 복잡한 확률 계산(MCMC)이 필요한 모델들이 주를 이뤘으나 학습이 매우 느리고 어려움

- 연구의 목표 : 검색기 + 생성기를 결합한 모델, RAG 구조 제안

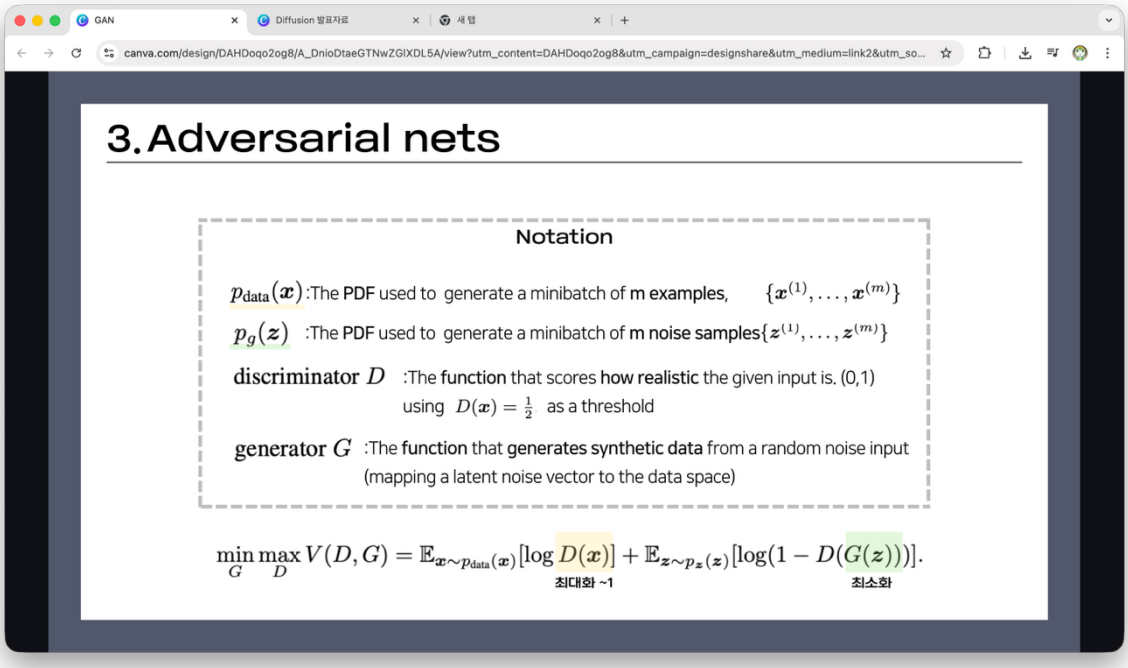

- 연구 접근법 및 모델 구조 (Method)

1. Retriever (검색기) : DPR 사용, 질문과 관련된 Top-K 검색
2. Generator (생성기) : BART 사용, 최종 답변 생성

→ Retriever + Generator end-to-end 학습 가능

- 실험 구성 및 결과 (Experiments)

1. MNIST(숫자), TFD(얼굴), CIFAR-10(사물) 데이터셋으로 실험 진행
2. 결과적으로 다른 최신 모델들과 비교했을 때 경쟁력 있는 수준의 깨끗한 샘플 이미지들을 생성

- 무엇을 발견했고 한계점은 무엇인지 (Discussion)

장점 : 복잡한 과정 없이도 선명하고 예리한 이미지를 생성

단점 : 생성된 데이터의 확률 분포를 수학적으로 직접 표현하기가 어려움

- 결론 및 주요 요약 (Conclusion)

: '경쟁'이라는 아이디어를 통해 성능 좋은 생성 모델을 만들 수 있음을 증명

〈 Denoising Diffusion Probabilistic Models 〉

- 어떤 문제를 해결하려 했는가? (Abstract)

: 확산 확률 모델(Diffusion Models)을 사용하여 매우 높은 품질의 이미지를 합성하는 방법 제시

- 연구 동기 및 문제점 (Introduction)

1. 딥러닝 생성 모델(GAN, VAE 등)은 눈부신 발전을 이뤘지만, 확산 모델은 구조가 단순함에도 불구하고 고품질 샘플을 생성할 수 있다는 점이 제대로 입증되지 않음
2. 확산 과정이 딥러닝 환경에서도 효율적으로 학습되고 고화질 이미지를 생성할 수 있음을 보여주고자 함

- 연구 접근법 및 모델 구조 (Method)

: 확산 모델을 최신 점수 매칭(Score matching) 기법 및 Langevin 역학(Dynamics)과 연결하여 이론적 기반을 강화

1. Forward Process (확산 과정): 깨끗한 이미지에 가우시안 노이즈를 단계적으로 추가하여 완전히 형태를 알 수 없는 노이즈로 만드는 과정
2. Reverse Process (역확산 과정): 노이즈 상태에서 시작해, 추가되었던 노이즈를 한 단계씩 제거(Denoising)하며 이미지를 복구하는 과정을 학습
3. 형태를 유지하며 노이즈를 예측하기 위해 U-Net 구조의 신경망을 사용

3.Diffusion models and denoising autoencoders

3.2 Reverse Process, (L1:t-1)

$$L_{t-1} - C = \mathbb{E}_{\mathbf{x}_0,\boldsymbol{\epsilon}}\left[\frac{1}{2\sigma_t^2}\left\|\tilde{\boldsymbol{\mu}}_t\left(\mathbf{x}_t(\mathbf{x}_0,\boldsymbol{\epsilon}), \frac{1}{\sqrt{\bar{\alpha}_t}}(\mathbf{x}_t(\mathbf{x}_0,\boldsymbol{\epsilon}) - \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon})\right) - \boldsymbol{\mu}_\theta(\mathbf{x}_t(\mathbf{x}_0,\boldsymbol{\epsilon}),t)\right\|^2\right] \tag{9}$$

$$= \mathbb{E}_{\mathbf{x}_0,\boldsymbol{\epsilon}}\left[\frac{1}{2\sigma_t^2}\left\|\frac{1}{\sqrt{\alpha_t}}\left(\mathbf{x}_t(\mathbf{x}_0,\boldsymbol{\epsilon}) - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}\right) - \boldsymbol{\mu}_\theta(\mathbf{x}_t(\mathbf{x}_0,\boldsymbol{\epsilon}),t)\right\|^2\right] \tag{10}$$

- 이미지 전체를 한번에 생성하는 것이 아닌 **노이즈 값(ϵ)을 찾는 방식으로 모델을 학습하는 것**
- ϵθ(xt,t) → **특정 시점 t와 이미지 Xt가 주어졌을때 해당 시점의 노이즈(ϵt)를 예측**하는 네트워크
- 수식을 이용해 평균 예측 문제를 노이즈 예측 문제로 바꿀 수 있어 loss가 훨씬 간단해짐
  - 특히 저자들은 ϵ을 예측하도록 loss term을 simplification하는게 성능이 좋다고 말함(ablation study)

- 실험 구성 및 결과(Experiments)

- CIFAR10, CelebA-HQ(얼굴), LSUN(침실, 교회) 등의 데이터셋에서 실험을 진행
- ProgressiveGAN 과 유사하거나 더 우수한 품질의 이미지를 생성

- 무엇을 발견했고 한계점은 무엇인가? (Discussion)

1. 확산 모델이 '손실 압축(Lossy Compression)'의 관점에서 매우 뛰어난 유도 편향(Inductive bias)을 가지고 있음을 발견

2. 생성 속도가 GAN 에 비해 느림