〈 TabNet: Attentive Interpretable Tabular Learning 〉

- 어떤 문제를 해결하려 했는가? (Abstract)

1. 정형 데이터에서 XGBoost 등 트리 모델 대비 딥러닝(DNN)의 성능 열세 및 해석력 부족

-〉 트리 모델의 장점(변수 선택, 해석력)과 딥러닝의 장점(엔드투엔드 학습, 유연성)을 결합한 새로운 아키텍처 제안

- 연구 동기와 문제점 (Introduction)

1. 과도한 파라미터화: 일반 DNN 은 모든 피처를 동시에 연산하여 노이즈에 취약하고 과적합 발생 가능성 높음

2. 구조적 공백: 정형 데이터는 이미지와 달리 픽셀 간 상관관계가 없으며, 불연속적인 결정 경계(Decision Boundary)를 가짐

3. 귀납적 편향(Inductive Bias) 부족: 정형 데이터 특유의 계단식 구조를 학습하는 데 트리 모델보다 불리함

- 연구의 목표 : 검색기 + 생성기를 결합한 모델, RAG 구조 제안

1. Instance-wise Selection: 전체 데이터가 아닌 각 입력 샘플(인스턴스)별로 최적의 피처를 다르게 선택

2. Sequential Attention: 여러 단계(Step)에 걸쳐 데이터를 순차적으로 처리하며 의사결정을 정교화

3. Soft Feature Selection: 역전파(Backprop)로 학습 가능한 마스크 $M[i]$를 사용하여 피처 선택과 예측을 동시 수행

- 연구 접근법 및 모델 구조 (Method)

1. Attentive Transformer: Sparsemax 를 통해 중요도가 낮은 피처를 완벽한 0 으로 제거하여 '희소 선택' 구현

2. Feature Transformer: Shared/Dependent 레이어 및 GLU(Gated Linear Unit)를 활용하여 복잡한 특징 추출

3. Prior Scale (P[i]): 특정 피처가 이전 단계에서 얼마나 사용되었는지 기록하여 중복 탐색 방지 및 다양성 확보

희소성 정규화(Sparsity Regularization)

$$L_{sparse} = \sum_{i=1}^{N_{steps}} \sum_{j=1}^{D} -M_{i,j} \log(M_{i,j} + \epsilon)$$

① i : Decision step의 인덱스
② j : 피처(Feature)의 인덱스
③ M_i, j : i번째 단계에서 j번째 피처에 적용된 마스크의 가중치

Interpretability 확보

전체 손실

$$Loss_{total} = Loss_{task} + \lambda_{sparse} L_{sparse}$$

예측 정확도와 해석력(희소성) 사이의 균형을 하이퍼파라미터로 조절,
마스크의 엔트로피를 최소화하여 모델이 가급적 적은 수의 핵심 피처만 사용하도록 강제

- 실험 구성 및 결과 (Experiments)
- 데이터 셋 구성
1. Classification: Forest Cover Type (581K 샘플), Adult Census Income (48K 샘플) 등
2. Regression: Rossmann Store Sales (1M 샘플), Higgs Boson (11M 샘플) 등
- 실험 결과
1. 성능 우위: 대부분의 벤치마크 데이터셋에서 XGBoost, LightGBM, CatBoost 등 기존 트리 앙상블 모델과 대등하거나 능가하는 성능 기록
2. 확장성(Scalability): 데이터셋 규모가 커질수록 딥러닝 특유의 표현 학습 능력이 발휘되어 성능 격차가 더 벌어짐
3. 효율성: 인스턴스별 피처 선택을 통해 불필요한 연산을 줄여, 일반 DNN 대비 적은 파라미터로도 높은 정확도 달성

- 무엇을 발견했고 한계점은 무엇인지 (Discussion)
장점 : 피쳐 선택의 유연성, 내재적 해석력, 범용성
단점 : 학습 속도 GPU 권장으로 인해 느림, 작은 데이터 셋의 경우 여전히 트리 모델이 성능 및 효율이 좋음

- 결론 및 주요 요약 (Conclusion)
: 순차적 어텐션을 통해 트리 모델의 변수 선택 능력과 딥러닝의 학습 성능을 성공적으로 결합한 아키텍쳐

〈 TabPFN: A Transformer That Solves Tabular Classification in a Second 〉

- 어떤 문제를 해결하려 했는가? (Abstract)

1. 지난 20 년간 정형 데이터는 GBDT(XGBoost 등)가 지배적이었으며, 딥러닝은 매번 데이터셋마다 새로 훈련하고 튜닝해야 하는 번거로움이 있었음
2. 훈련이 전혀 필요 없는 정형 데이터용 기초 모델(Foundation Model)을 구축하여, 1 만 개 이하의 샘플에서 기존 모든 모델을 압도하는 성능과 속도 구현

- 연구 동기 및 문제점 (Introduction)

1. 지도 학습의 비효율성: 새로운 데이터가 들어올 때마다 수 시간 동안 하이퍼파라미터 최적화(HPO)를 거쳐야 함
2. 소규모 데이터의 난제: 샘플 수가 적을 때 딥러닝은 일반화 성능이 급격히 떨어지며 트리 모델에 밀리는 경향이 있음
3. 텍스트의 LLM 처럼, 정형 데이터에서도 사전 학습된 지식을 통해 즉각적인 추론(In-context Learning)이 가능한 모델 개발

- 연구 접근법 및 모델 구조 (Method)

1. In-Context Learning: 모델 가중치를 수정하지 않고, 입력된 훈련 데이터 자체를 '맥락'으로 사용하여 테스트 샘플의 라벨을 예측
2. Amortized Bayesian Inference: 복잡한 베이지안 사후 확률 계산을 트랜스포머의 단 한 번의 Forward Pass 로 근사(2.8 초 만에 4 시간 튜닝한 앙상블 모델 능가)
3. Foundation Model 화: 분류뿐만 아니라 회귀, 데이터 생성(Synthetic Data), 결측치 보충 등 다양한 태스크로 확장 가능

Principled in context learning

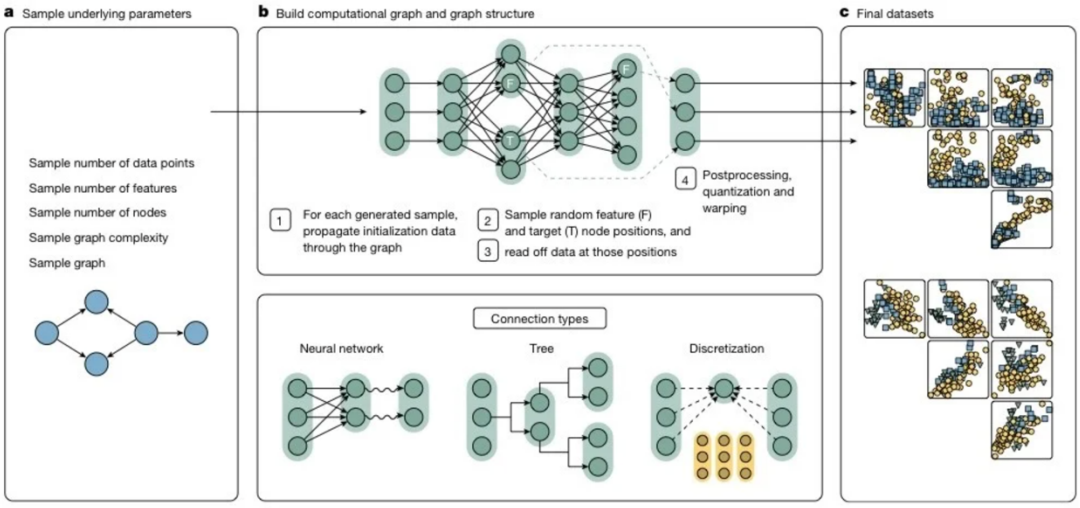

- Transformer-based Architecture: 샘플 간, 피처 간의 고차원적 관계를 파악하기 위해 어텐션(Attention) 메커니즘 활용
- Prior-Data Fitting (사전 학습): 베이지안 사전 확률로부터 생성된 수많은 합성 데이터셋으로 모델을 학습
- Scaling: 모델의 크기와 사전 학습 데이터의 양을 늘릴수록 실제 데이터셋에서의 성능이 지속적으로 향상됨을 확인

- 실험 구성 및 결과(Experiments)
- Zero-shot 성능: 1 만 개 미만의 데이터셋에서 4 시간 동안 튜닝한 최강의 모델들보다 단 수 초 만에 더 높은 정확도 기록
- Kaggle 데이터셋 검증: 실제 경진대회 데이터에서도 별도의 트릭 없이 상위권 성능 발휘

- 무엇을 발견했고 한계점은 무엇인가? (Discussion)

1. 거대 모델의 사전 학습 효과가 강력하게 나타남. 복잡한 정형 데이터를 완벽하게 이해함
2. 메모리의 제약(대규모 데이터 셋의 경우 바로 적용하기 어려움). 피처 수의 제한